

بنام خدا

گزارش تمرین دوم

موضوع تمرین:

تحلیل داده مربوط به **DDOS**

استاد:

دکتر تاجبخش

سینا زینالی بایرامی

۱۴۰۴۶۹۹۱۱۱

زمستان ۱۴۰۴



فهرست مطالب

۳	فصل اول
۳	مقدمه
۳	معرفی دیتاست
۵	فصل دوم
۵	Imbalance data
۶	Correlation analysis
۷	فصل سوم
۷	مدل های یادگیری
۷	ارزیابی عملکرد مدل ها
۹	Shap
۱۱	جلوگیری از Leakage
۱۲	نتیجه گیری
۱۳	لينک گيت هاب



فصل اول

مقدمه

با گسترش اینترنت اشیاء، مشکلات امنیتی مرتبط با این تکنولوژی نیز افزایش یافت. از آنجا که دستگاه‌های IOT معمولاً سطح امنیت پایین‌تری دارند، اهداف مناسبی برای اجرای حمله DDOS هستند. در این حملات با ارسال حجم زیادی از ترافیک بیهوده، موجب از کار افتادن سرویس هدف می‌شوند.

بررسی داده‌های شبکه با استفاده از ماشین لرنینگ، یکی از روش‌های شناسایی و classification حملات محسوب می‌شود.

هدف این پژوهه تحلیل داده‌های مربوط به حمله DDOS در IOT با استفاده از دیتاست BOT-IOT و بررسی عملکرد سه مدل درختی مختلف است.

معرفی دیتاست

در این تمرین از دیتاست BOT-IOT استفاده شده است که شامل ترافیک شبکه شبیه‌سازی شده در محیط IOT است. طبق تعریف تمرین از فایل csv موجود در فolder %۵ استفاده شده است. نام فایل نیز UNSW_2018_IoT_Botnet_Full5pc_2.csv بود. این داده‌ها شامل حدود یک میلیون نمونه و ۴۶ فیچر است که شامل اطلاعاتی مانند تعداد پکت‌ها، حجم داده، نرخ ارسال و ... بود. (شکل ۱-۱)

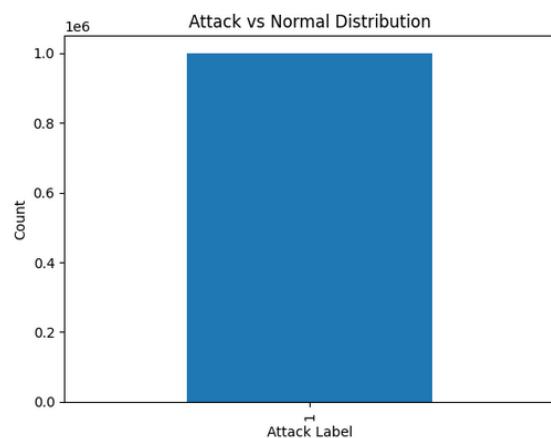
# Basic info	print(df.shape)	df.head()														
<pre> </pre>																
<pre>C:\Users\szb20\AppData\Local\Temp\ipykernel_18300\2020635744.py:6: DtypeWarning: Columns (7,9) have mixed types. Specify dtype option on import or set low_memory=False.</pre>																
<pre>df = pd.read_csv('../data/UNSW_2018_IoT_Botnet_Full5pc_2.csv')</pre>																
0	(1000000, 46)															
pkSeqID	stime	flgs	flgs_number	proto	proto_number	saddr	sport	daddr	dport	...	AR_P_Proto_P_DstIP	N_IN_Conn_P_DstIP	N_IN_Conn_P_SrcIP	AR_P_Proto_P_Sport	AR_P_Proto_P_Dport	Pkts_F
0	1000001	1.528085e+09	e	1	udp	3	192.168.100.148	37153	192.168.100.6	80	...	0.319943	100	100	0.319979	0.319943
1	1000000	1.528085e+09	e	1	udp	3	192.168.100.148	37154	192.168.100.6	80	...	0.319943	100	100	0.319979	0.319943
2	1000003	1.528085e+09	e	1	udp	3	192.168.100.148	37155	192.168.100.6	80	...	0.319943	100	100	0.319979	0.319943
3	1000004	1.528085e+09	e	1	udp	3	192.168.100.148	37156	192.168.100.6	80	...	0.319943	100	100	0.319979	0.319943
4	1000005	1.528085e+09	e	1	udp	3	192.168.100.148	37157	192.168.100.6	80	...	0.319943	100	100	0.319979	0.319943

(شکل ۱-۱) - اطلاعات داده ها

لیبل های موجود در این دیتا به صورت زیر بود:

- Attack : حمله یا عدم حمله
- Category : نوع حمله
- Subcategory : زیرنوع حمله

در بررسی اولیه داده ها مشخص شد که فایل انتخاب شده، صرفا شامل ترافیک حمله بود. بنابراین مدل ماشین لرنینگ مسئله classification دوتایی بین دو نوع حمله DOS و DDOS است. (شکل ۱-۲)



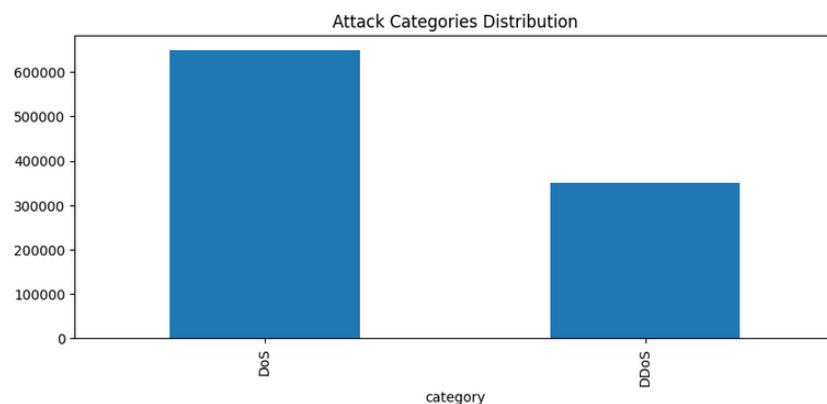
(شکل ۱-۲) - دسته بندی حمله یا عدم حمله

فصل دوم

یکی مراحل preprocessing، بررسی توزیع داده‌ها است. عدم توازن داده‌ها می‌تواند باعث جهت‌گیری مدل به یک کلاس خاص بشود.

Imbalance data

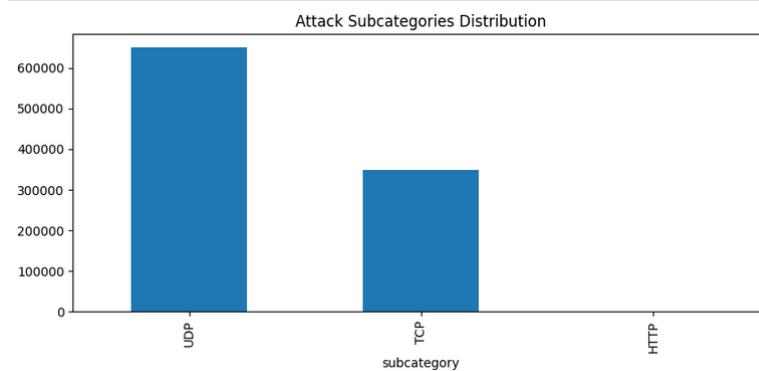
در ابتدا توازن داده‌ها بر اساس لیبل category بررسی شد. (شکل ۲-۱)



(شکل ۲-۱) دسته بندی نوع حمله

در نمودار مشاهده می‌شود که دیتا شامل دو کتگوری DOS و DDOS است که توزیع آن نیز کمی نامتوازن است.

در ادامه این توازن براساس لیبل subcategory مورد بررسی قرار گرفت. (شکل ۲-۲)

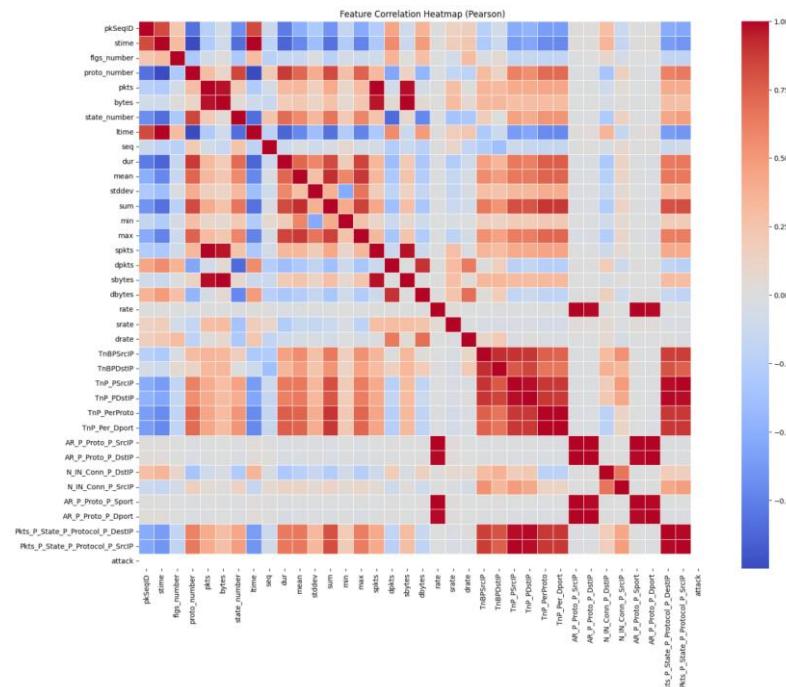


(شکل ۲-۲) دسته بندی

نتایج این نمودار نشان می‌دهد که حملات با پروتکل UDP بیشترین فراوانی را دارند. همچنین subcategory حمله مبتنی بر HTTP سهم بسیار کوچکی از داده را شامل می‌شود. مدل‌های یادگیری ماشین در تشخیص این نوع حملات عملکرد ضعیف‌تری خواهند داشت.

Correlation analysis

در مرحله بعدی همبستگی بین ویژگی‌های عددی داده‌ها را با استفاده از ضریب همبستگی pearson محاسبه کردیم. نتایج به صورت heatmap به صورت زیر است. (شکل ۲-۳)



(شکل ۲-۳) correlation heatmap



فصل سوم

مدل های یادگیری

در این تمرین برای classification انواع حملات DOS و DDOS از سه مدل مبتنی بر درخت تصمیم استفاده شده است.

- Random Forest: مدلی مبتنی بر تجمعی چندین درخت تصمیم که با کاهش واریانس، عملکرد پایداری را در مسائل classification ارائه می دهد.
- XGBoost: یکی از قدرتمندترین الگوریتم های Gradian Boosting که با بهینه سازی تدریجی خطأ، توانایی بالایی در یادگیری الگوهای پیچیده دارد.
- CatBoost: الگوریتم مبتنی بر Boosting که به ویژه در برخورد با ویژگی های دسته ای عملکرد مناسبی از خود نشان می دهد و نیاز کمتری به پیش پردازش داده ها دارد.

ارزیابی عملکرد مدل ها

نتایج به دست آمده نشان داد هر سه مدل عملکرد کاملاً صحیح داشته اند و بررسی confusion matrix نشون میده مقدار خطأ همه مدل صفر و یا فقط ۱ عدد بوده است. در ادامه مقادیر precision، recall و accuracy هر مدل را می بینیم. (شکل ۲-۳) (شکل ۳-۱) (شکل ۳-۳)

Random Forest Confusion Matrix:					
		precision	recall	f1-score	support
0	1.00	1.00	1.00	1.00	130052
1	1.00	1.00	1.00	1.00	69948
		accuracy		1.00	200000
		macro avg		1.00	200000
		weighted avg		1.00	200000

Random Forest - مدل (۳-۱) (شکل)



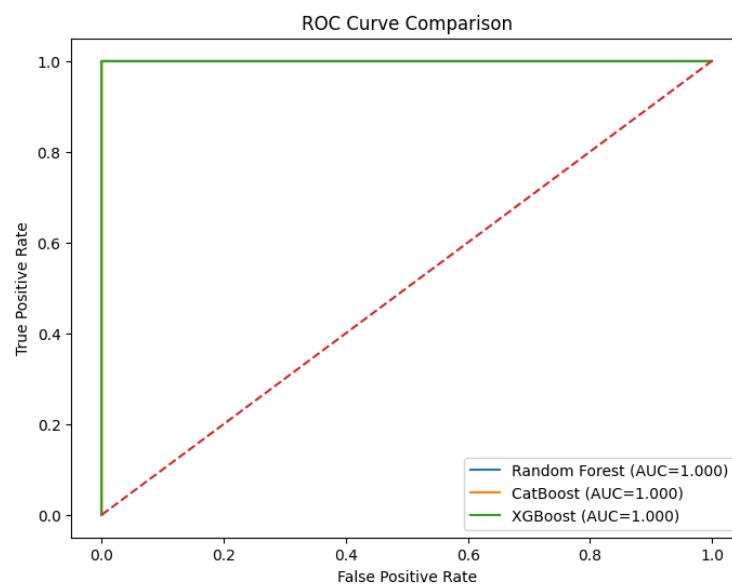
[[130051 1]			
[0 69948]]			
precision recall f1-score support			
0 1.00	1.00	1.00	130052
1 1.00	1.00	1.00	69948
accuracy		1.00	200000
macro avg	1.00	1.00	1.00
weighted avg	1.00	1.00	1.00

CatBoost مدل - (۳-۲) (شکل)

[[130052 0]			
[0 69948]]			
precision recall f1-score support			
0 1.00	1.00	1.00	130052
1 1.00	1.00	1.00	69948
accuracy		1.00	200000
macro avg	1.00	1.00	1.00
weighted avg	1.00	1.00	1.00

XGBoost مدل - (۳-۳) (شکل)

در ادامه نمودار ROC نیز رسم شد. (شکل ۳-۴)



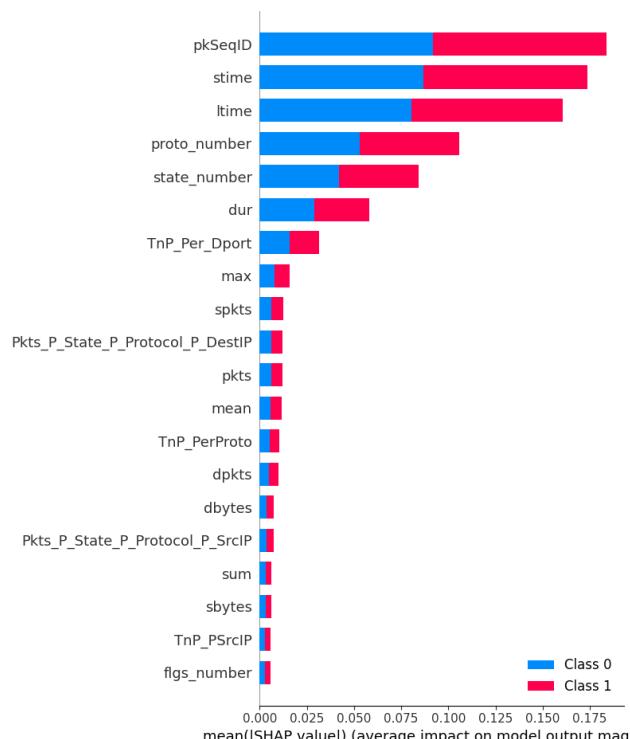
ROC نمودار (شکل ۳-۴)

اگرچه دقت ۱۰۰٪ کاملاً درست به نظر می‌رسد، اما نتایج به دست آمده نیازمند تحلیل دقیق‌تری هستند. بررسی‌های انجام‌شده در بخش‌های قبلی نشان داد که مدل‌ها تمایل دارند به تعداد محدودی از ویژگی‌ها وابسته شوند. این مسئله می‌تواند نشان‌دهنده‌ی ساده بودن الگوی جداسازی کلاس‌ها در داده باشد. همچنین وجود ویژگی‌هایی باشد که به صورت مستقیم یا غیرمستقیم اطلاعات مربوط به لیبل را در خود نیز موثر باشد.

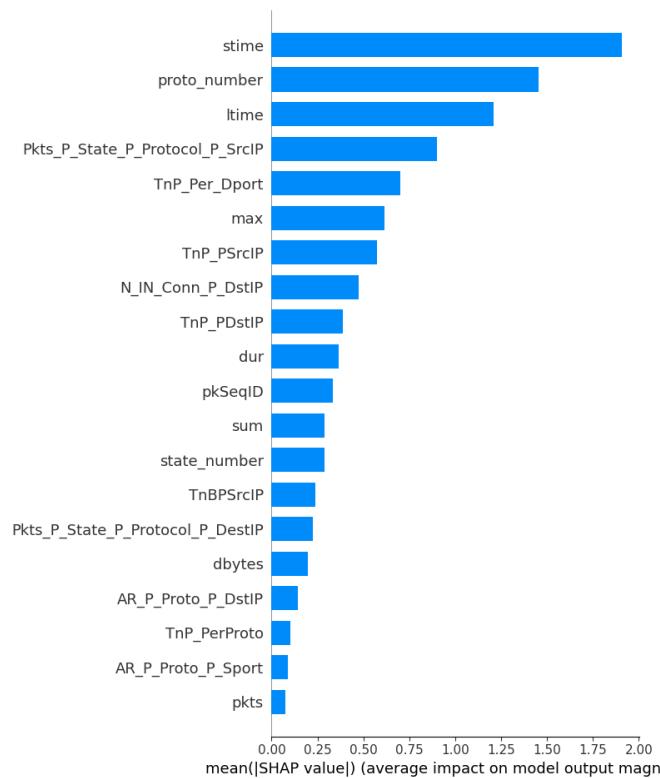
علاوه بر این، عدم توازن داده‌ها نیز می‌تواند بر نتایج ارزیابی تاثیرگذار باشد و باعث شود که برخی معیارها بیش از حد خوش‌بینانه گزارش شوند. بنابراین، نتایج این پروژه بیشتر از آن‌که نشان‌دهنده‌ی برتری یک مدل خاص باشند، بیانگر ویژگی‌های ذاتی مجموعه‌داده و ساختار حملات موجود در آن هستند.

Shap

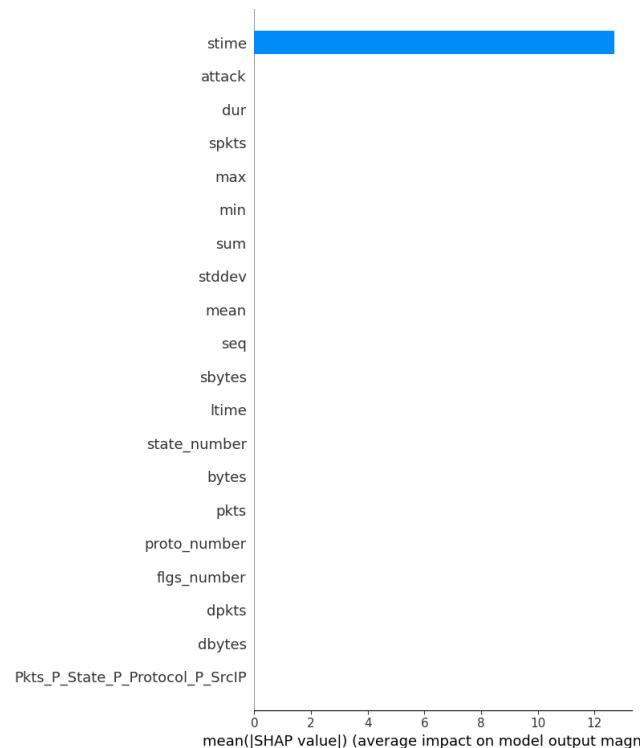
در مرحله بعدی برای هر سه مدل نمودار *shap* را رسم کردیم تا بررسی کنیم که هر یک از فیچرها چقدر تاثیر دارند. (شکل ۳-۵) (شکل ۳-۶) (شکل ۳-۷)



(شکل ۳-۵) - نمودار *shap* مدل RF



CatBoost مدل shap نمودار - شکل ۳-۶

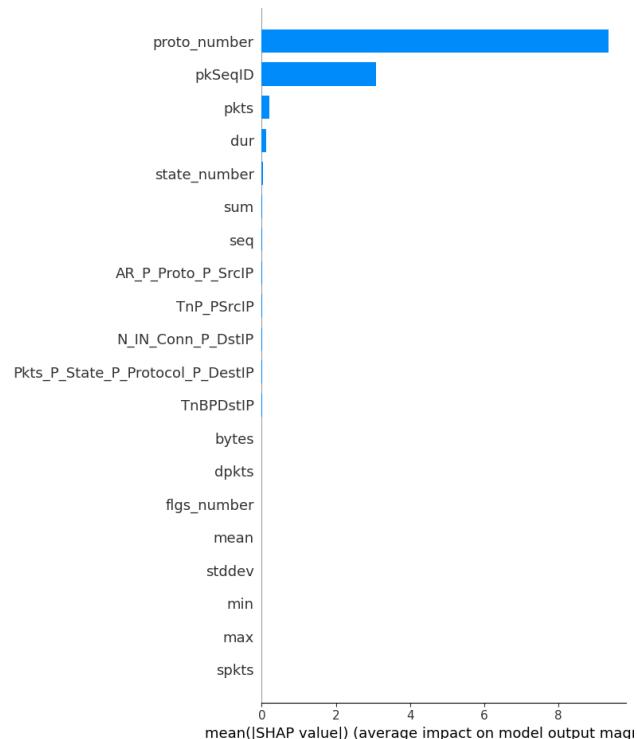


XGBoost مدل shap نمودار - شکل ۳-۷

نمودار shap مربوط به مدل XGBoost، نشون میده که این نمودار فقط بر اساس stime، نوع حمله را تشخیص می‌دهد و بقیه فیچرها را نادیده می‌گیرد. این مثالی از data Leakage است.

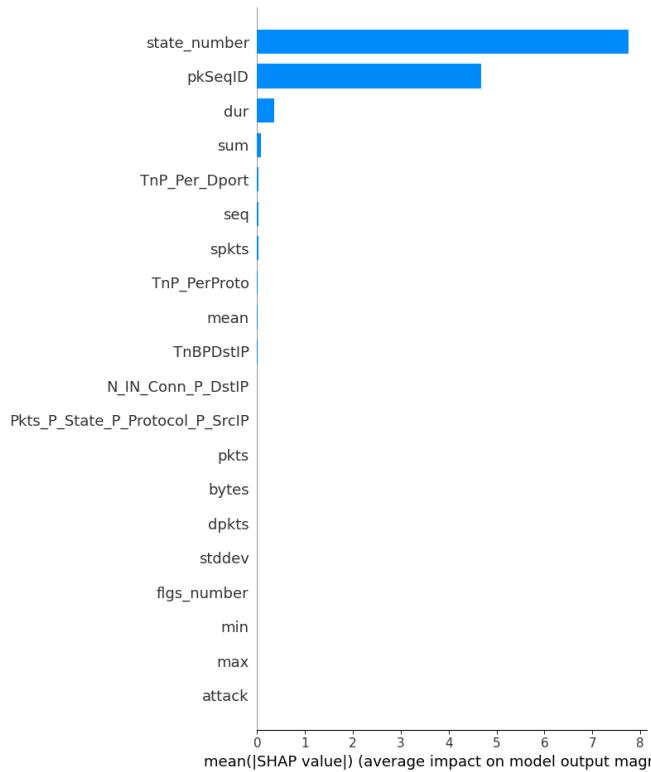
جلوگیری از Leakage

در بخش قبلی دیدیم که در مدل XGBoost data leakage اتفاق افتاده است و فقط بر اساس stime تصمیم گیری می‌کند. برای این که از این اتفاق جلوگیری کنیم، از داده‌ها ستون‌های ltime و recall، accuracy همانند قبل بود و مقدار ۱۰۰ درصد بود. نمودارهای shap دو مدل دیگر تغییر آنچنانی نداشتند اما نمودار مدل XGBoost به صورت تغییر یافت. (شکل ۳-۸)



شکل ۳-۸ - نمودار shap بعد از حذف stime, ltime مدل XGBoost

مشاهده می‌کنیم که تا حدودی از data leakage جلوگیری شده است. برای بهبود عملکرد مدل، در مرحله بعدی ستون proto_number را نیز از دیتا ست حذف کردیم و همچنان ۱۰۰٪ accuracy بود. (شکل ۳-۹)



(شکل ۹) - نمودار XGBoost مدل shap بعد از حذف stime,ltime,proto_number

مشاهده می‌کنیم که این مدل این بار به فیچر های PakSeq_ID و state_num متکی هست و سایر فیچرهای در یادگیری مدل تاثیری ندارند.

نتیجه گیری

در این پروژه، تحلیل داده‌های مربوط به حملات DDoS و DoS در شبکه‌های IOT با دیتاست مشخص انجام شد. در ابتدا، بررسی داده‌های نشان داد که داده‌ها از نظر کلاس‌های هدف و زیردسته‌های حمله دارای عدم توازن قابل توجهی هستند که این موضوع می‌تواند بر ارزیابی عملکرد مدل‌های یادگیری ماشین تأثیرگذار باشد.

در نهایت پس از آموزش مدل‌ها، با روش SHAP، اهمیت فیچرها در تصمیم‌گیری مدل‌ها بررسی شد. نتایج نشان داد مدل‌ها، مخصوصاً مدل XGBoost، تمایل دارند به فیچرها محدودی وابسته باشند و data leakage رخ داد. با حذف برخی ستون‌ها برای رفع این مشکل تلاش کردیم و هر بار ستون دیگری متکی شد. این نشان دهنده اسن هست که دیتاست موردنظر به طور ذاتی نوع حمله را encode کرده و حذف تدریجی ستون‌ها فقط باعث جابجایی منبع leakage می‌شود.



لینک گیت هاب

در ادامه لینک گیت هاب مربوط به کد های پروژه قرار داده شده است.

<https://github.com/sinazb/DDOS-Analysis-BotIoT>